

文章编号: 0465-7942(2022)03-0029-06

基于WIFI信息熵特征分析的室内人员行为监测技术

杜宇峰^{1,2,3}, 王春东^{1,2,3}, 杨文军^{1,2,3}, 张炜宁^{1,2,3}, 汪卓越^{1,2,3}

(1. 计算机视觉与系统教育部重点实验室, 天津 300384; 2. 天津市智能计算及软件新技术重点实验室, 天津 300384;
3. 计算机病毒防治技术国家工程实验室, 天津 300384)

摘要: 现有的室内监控技术存在一些限制,例如盲区和高成本.相反,无线传感技术因其非视距和被动的优点受到广泛研究.现有的基于无线信号的检测方法大多采用信号强度和信道状态信息(CSI)的测量值.然而,实验证明从同一设备接收的信号随不同天线有差异.计算出不同天线间相位差时频图的熵值可以作为有效特征提高检测率.利用无线设备在3种常见室内环境中采集的数据提取相位差特征,并与现有的特征提取方法进行比较.同时选取支持向量机(SVM)和神经网络分类方法对比.结果表明,该方法具有较高的准确性和鲁棒性.

关键词: 无线感知; 室内安防; 信道状态信息; 信息熵

中图分类号: TN92

文献标识码: A

0 引言

WiFi信号在空气中发散传播,通过不同路径以不同的相位到达接收器.当设备附近有人体移动时会信号产生反射、折射等影响,使信号产生波动,通过分析WiFi信号可以实现人体的检测和定位^[1-2]等.而目前室内的安全管理手段主要包括红外线、摄像头等.两者均存在不足之处,红外线设备利用红外线对人体进行成像,感应范围有限并且需要部署昂贵的设备;视频监控由单个可见光摄像机组成^[3],容易受到光线的影响,且监控范围仅限于视距路径,两者均无法大面积投入使用.而现有的WiFi设备广泛应用于各个场所,部署成本低,不受视距路径限制,并且不需要用户携带任何设备就可以达到检测效果.因此,基于WiFi设备的被动式人员检测系统对各种室内环境、公共场所以及智能家居均有良好的应用前景.

近年来,研究WiFi设备来实现人员行为分析的工作越来越深入.许多的研究重点开始致力于与机器学习方法的结合,以及发掘更细粒度的特征以识别细微、复杂的动作.因此,更多研究工作的研究点从原始的信号强度信息(received signal strength indication, RSSI)转向包含更多信息的CSI.原本RSSI已经广泛运用于室内定位系统,但是从设备上获取的RSSI传输时没有经过调解,易受多径等复杂环境的影响,在特殊情况下,系统的性能存在低效率、低精度等局限性^[4-5].相比于RSSI,CSI经过调解后具有更高细粒度和稳定性,同时更多的工具带来了更好的可访问性.文献[6]使用机器学习中支持向量机的分类方法对收集到的CSI振幅和相位信息进行分类,通过设定敏感目标的检测阈值实现人体运动速度的检测.

除此之外,还有很多研究通过构建神经网络的深度学习模式来对WiFi设备信号进行分析.文献[7]提出的WiQ系统研究了驾驶行为的质量评价问题,通过将RSSI信号分段处理,生成特征矩阵作为神经网络的输入进行训练分类,通过选取特征的不同,实现汽车环境内驾驶员身份以及精细动作的识别.文献[8]提出一种无线信号图像处理办法,将CSI信号多个子通道的图像处理成一个无线电图像,提取颜色、纹理等特征,然后采用深度学习网络获取深层的特征以达到分类识别的效果.

近期有研究发现可以从CSI信号中获取移动人员的多普勒信息作为检测手段,文献[9]提出了一种适用于移动人员的穿墙模型检测系统,通过计算CSI的平均多普勒频谱来获得信道频率随时间的变化规律.

收稿日期: 2021-03-21

基金项目: 国家自然科学基金(U1536122);天津市科委面上项目(15JCYBJC15600);天津市科委重大专项(15ZXDSGX00030)

作者简介: 杜宇峰(1994-),男,山西晋城人,硕士研究生.

通讯作者: 王春东(1969-),男,天津人,教授,研究方向:网络信息安全技术. E-mail: michael3769@163.com

同时,也有研究表明雷达信号的信息熵值包含了移动物体的多普勒信息,文献[10]研究了导弹微动时回波的时频变化特性,提出对运动物体的瞬时多普勒线性和做傅里叶变换方法.文献[11]研究了两种基于时频分析的飞机目标特征提取算法,利用短时傅里叶变换获得目标二维时频图信息.

提出一种基于WiFi信息熵特征的室内人员行为检测方法.首先收集WiFi设备中的CSI信息,然后通过过去噪声和数据降维技术对信号处理,从中提取包括波形熵值在内的特征值.最后构建了一个4层的卷积神经网络(convolutional neural networks, CNN)作为分类器.

1 系统架构和特征分析

如图1所示,系统由3个部分组成,首先由天线组成的收发设备收集WiFi信号数据包,然后通过工具从数据包中获取CSI中的相位信息并进行去噪声处理,降维处理后计算每个维度的特征值生成一个特征矩阵作为分类器输入.最后将收集到的数据分为训练集和测试集,训练CNN分类器.

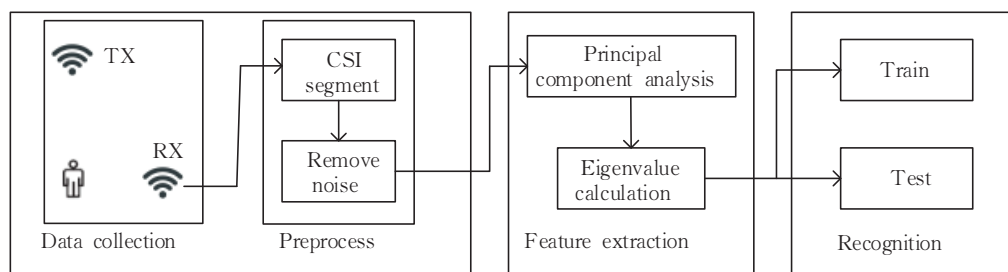


图1 系统架构

Fig.1 System framework

1.1 信号收集和预处理

在信号收集阶段,使用1个天线作为发射端,接收端为3个天线,在发射端设定采样率后定期发送含有CSI信息的数据包,CSI是正交频分复用技术中对物理层信道状态的估计,每条天线链路都有对应的CSI值.假设发射机和接收机个数分别为 m 和 n ,子载波个数为 x ,对应的数据包中是一个 $m \times n \times x$ 的矩阵,从中可以获取需要的CSI信息.每个天线含有30个子载波,不同子载波含有不同信息,所以由接收端接收到的采样包中提取的CSI矩阵 H 大小为 $1 \times 3 \times 30$.按时间获取的数据包可以表示为一系列的CSI矩阵:

$$C = [H_1, H_2, \dots, H_i] \quad (1)$$

其中, i 为数据包长度.

无线信号在传播中易受到干扰,如多径效应、环境变化,对于一组接收设备,不同情况下接收到的信号会产生较大偏差,此时选择两个天线CSI信号之间的相位差更有利,因为对于同时接收信号的一组接收机来说,信号自身的各种噪音以及多径影响是同时存在的,具有更好的鲁棒性.因此首先用低通滤波器对获取的信号去除噪声,然后将两个天线的相位值按时间序列做差.

1.2 特征分析

获得相位差后,考虑到减小数据量对运算效率的影响,并保证足够的特征数量作为CNN的输入,将30个子载波的相位差作为30维向量进行主成分分析降维处理.经过验证保存为8维数据时可以保证超过90%的贡献率,即生成的数据可以很好的表示原始数据的波动特征.图2为实验中开门时一子载波的原始以及滤波和降维后的相位差波形图,设定发包速率为1 000,采集了4 s的数据,当动作部分开始时,相位差出现明显变化.




图2 相位差波形图

Fig.2 Phase difference waveform

针对两个波形波动情况和离散程度之间的相似度,采用的统计学特征主要有:平均绝对误差、方差、四分位差、极差、标准差.除此之外,通过对数据统计获得的特征值包括设定阈值后的波峰和波谷个数,即选定一个阈值,然后统计超过这个阈值的波峰和波谷个数,以此提取信号中的波动特性.

与雷达回波的时频图类似,CSI 信号时频图可以反映任意时刻受运动物体干扰所带来的多普勒信息,当有人体在非涅尔区内移动时,信号波形较无人时峰值分布更为密集,根据这个特点,可以提取相位差时频图波形的熵值作为有效的识别特征,来体现

波形的散布特性,选取的8个特征值如表1所示.

表1的特征值公式中, $x_1 \cdots x_n$ 代表CSI相位差序列值, \bar{x} 代表序列平均值, n 代表序列长度,四分位差公式中, Q_3 和 Q_1 分别表示数列的上四分位数和下四分位数,极差公式中, x_{\max} 和 x_{\min} 分别代表序列的最大值和最小值,信息熵公式中, P_i 表示在所选取的频谱区间范围内,频点 i 出现的频率.

1.3 分类器

CNN神经网络是现在主流的一种深度学习

方法,广泛应用于图像、文字、语音等领域的识别^[12-13].通常CNN的输入是一个矩阵,比如一个 28×28 的灰度值图像,通过卷积层和池化层获得图像的特征,反复训练网络参数后进行分类.

构建了一个四层的CNN网络作为分类器,CNN网络结构如图3所示,分为输入层、两个卷积层,一个池化层和全连接层.输入即为通过表1获得8维数据的 8×8 特征矩阵,两个卷积层的卷积核大小均为 3×3 ,第一个卷积层将一个通道映射到6个通道(选取6种不同的局部特征),后一个卷积层将6个通道映射到12个通道.步幅设为1,两个卷积层后使用ReLU激活函数.在池化层为了避免同一特征重复,选用最大池化消减分辨率,将每个通道的大小变为 1×1 ,此时每条数据的大小为 $12 \times 1 \times 1$,成为一维向量后输入全连接层,最后成为一个四分类问题.利用Matlab环境搭建神经网络,每个epoch输入网络的batchsize值为30,网络基于CrossEntropyLoss损失函数进行训练.




图3 搭建的CNN结构示意图

Fig.3 The structure diagram of CNN built

2 实验设计和结果分析

2.1 实验设计

实验中使用两台mini-PCs机作为发射设备和接收设备,两台机器均装有5300 WiFi NICs和3个天线,使用Ubuntu10.04系统,安装CSI tools工具包后可以接收CSI信号.实验中,发射设备使用一个天线,设置为injector模式广播信号,附近可以接收wifi信号的设备都能接收到信号,接收设备使用3个天线,设置为monitor模式,工作频率设置为5.32 GHz band.

实验环境如图4所示,分别为一个 $8 \text{ m} \times 9 \text{ m}$ 的工作室、一个 $8 \text{ m} \times 8 \text{ m}$ 的会议室以及一个空旷的天台,

每次采集的数据一共分为4组:无人、开门、走向接收机、其他路径.实验中请一名志愿者在房间内开门和沿不同方向行走,对于每组数据采集100次,从中选取90个样本作为训练集,10个样本作为测试集.并从训练集中随机抽取样本替换测试集进行两次交叉实验,最后计算3个房间检测率的平均值作为实验结果.

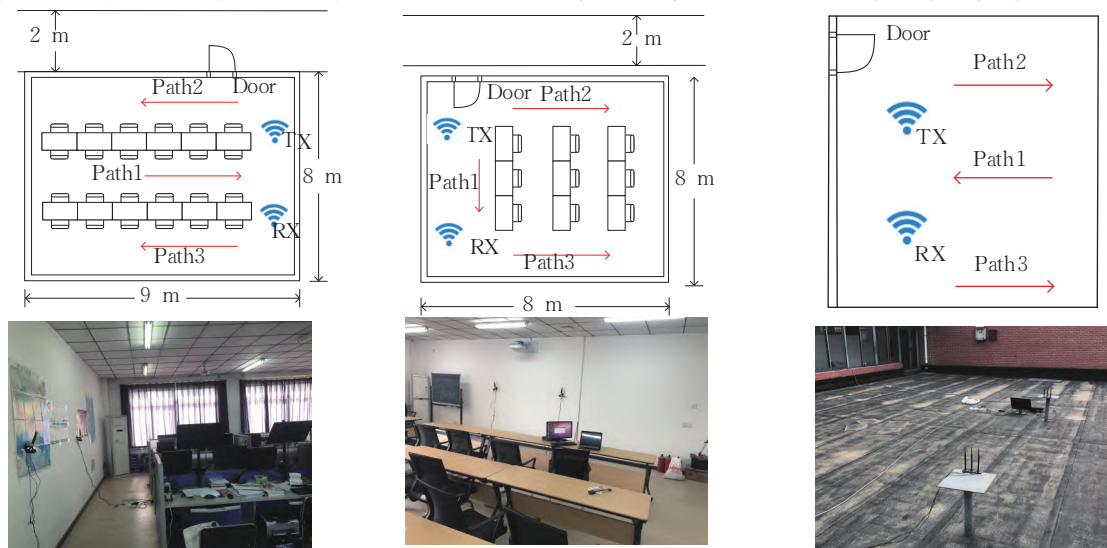


图4 实验环境

Fig.4 Experimental environment

实验总共分为两组对比实验,第1组实验对比本文的特征提取方法与现有论文中的特征提取方法,在特征提取阶段,提取特征的数据分为3组:信号的RSSI值序列、CSI信号振幅值序列、CSI信号相位差序列.前两者均取自同一个接收设备的天线,3组数据均采用CNN神经网络进行训练分类,结果如图5(a)所示.第2组实验对比CNN神经网络与其他分类器,3个场景采集的数据均采用本文的特征提取方法.在训练分类阶段,选用支持向量机和概率神经网络作为对比,两者分别使用Matlab的SVM工具箱和神经网络工具箱搭建,前者采用径向基核函数,首先用交叉验证获得最佳参数,然后用最佳参数训练模型;后者含有一层中间层,权值函数为欧式距离函数,传递函数为高斯函数,结果如图5(b)所示.

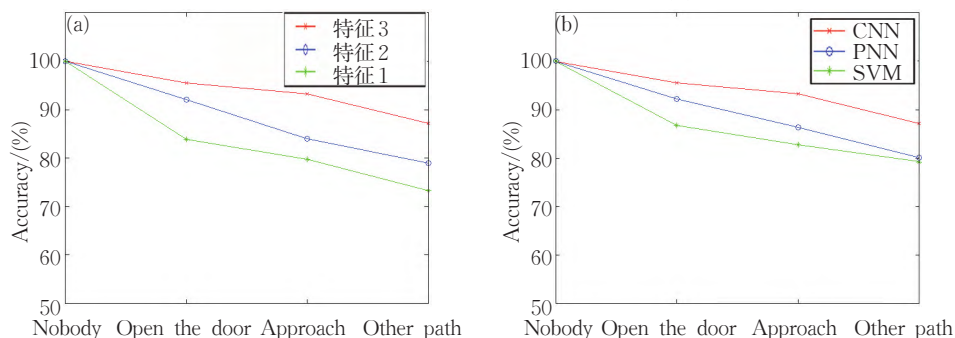


图5 实验结果

Fig.5 Experimental result

2.2 结果分析

实验结果表明:使用本文提出的方法计算天线间的相位差,得到信号频谱图的波形熵值可以作为识别人员靠近和开关门的有效特征,较采用RSSI和CSI测量值的特征值分类效果更好.在3个室内环境下均有较高检测率,准确率为87.1%—95.5%.

实验中发现无人、有人靠近、开门时的波形熵值分布于不同的区间,如图6所示.同时,结果表示在数据集中增加多种识别目标后,系统准确率降低,这是由于当人体以较小速度穿越菲涅尔区时,对信号的干扰时间间隔较少,导致引起的变化类似,尤其是靠近发射和接收设备时,菲涅尔区较为密集,很难从单一角度辨别不同情况时信号的变化程度.解决这个问题的方法是从信号中提取更高细粒度的特征,从而加强系

统对目标的识别能力,提高分类准确率。

在实验中很多因素会受到限制,比如采集数据的场景需要保持不变,并且保证附近行走的人员只有一个,在未来,将会进行更多的实验来研究这些因素对实验结果的具体影响,针对这些问题一些研究已经提出了一些可行的针对方法^[14-15]。同时会增加更多的识别目标,比如人员的手势、跳动、摔倒,使其更适合实际情况的使用。




图6 波形熵值分布

Fig.6 Waveform entropy distribution

4 结 论

提出了一种基于信息熵特征分析的具有高鲁棒性的室内人员行为监测方法.针对目前WiFi传输时携带的CSI信号,为了获取更多的信息,从信号时频图中提取更多特征对目标识别研究有很重要的价值,本文使用的方法从相位差时频图的信号角度和图像角度研究了分类手段,表明在提取特征时CSI信号可以提供多种的选择.与现有的其他室内监视技术相比,所使用的方法具有非侵入性和隐私保护等优点,以后会通过这个模型来扩展工作,包括对更高细粒度动作的识别以及检测系统在不同环境下的覆盖效果。

参 考 文 献

- 1 Yang Z, Zhou Z, Liu Y. From RSSI to CSI : indoor localization via channel response[J]. Acm Computing Surveys, 2013, 46(2): 1-32.
- 2 Tong X, Guo B, Wang Z, et al. FreeSense: human-behavior understanding using Wi-Fi signals[J]. Journal of Ambient Intelligence and Humanized Computing, 2018, 9(5): 1 611-1 622.
- 3 Xiao F, Chen L, Sha C H, et al. Noise tolerant localization for sensor networks[J]. IEEE/ACM Transactions on Networking, 2018, 26(4): 1 701-1 714.
- 4 Xiao F, Wang Z, Ye N, et al. One more tag enables fine-grained RFID localization and tracking[J]. IEEE/ACM Transactions on Networking, 2018, 26(1): 161-174.
- 5 Zeng Y, Pathak P H, Mohapatra P. WiWho: WiFi-based person identification in smart spaces[C/OL]//2016 15th ACM/IEEE International Conference on Information Processing in Sensor Networks (IPSN), Vienna, Austria, April 11-14, 2016. (2016-04-28)[2021-02-13]. <https://ieeexplore.ieee.org/document/7460727>.
- 6 Qian K, Wu C, Yang Z, et al. PADS: Passive detection of moving targets with dynamic speed using PHY layer information[C/OL]//2014 20th IEEE International Conference on Parallel and Distributed Systems (ICPADS), Hsinchu, Taiwan, Dec 16-19, 2014. (2015-04-30)[2021-02-13]. <https://ieeexplore.ieee.org/document/7097784>.
- 7 Lü S, Lu Y, Dong M, et al. Qualitative action recognition by wireless radio signals in human-machine systems

- [J]. IEEE Transactions on Human-Machine Systems, 2017, 47(6): 789–800.
- 8 Gao Q, Wang J, Ma X, et al. CSI-based device-free wireless localization and activity recognition using radio image features[J]. IEEE Transactions on Vehicular Technology, 2017, 66(11): 10 346–10 356.
 - 9 Domenico S D, Sanctis M D, Cianca E, et al. WiFi-based through-the-wall presence detection of stationary and moving humans analyzing the doppler spectrum[J]. IEEE Aerospace and Electronic Systems Magazine, 2018, 33(5/6): 14–19.
 - 10 王 璐, 刘宏伟. 基于时频图的微动目标运动参数提取和特征识别的方法[J]. 电子与信息学报, 2010, 32(8): 1 812–1 817.
 - 11 姜 悦, 范菊平, 郭乐田, 等. 基于时频图的飞机目标特征提取算法[J]. 现代雷达, 2016, 38(4): 38–41.
 - 12 He K, Zhang X Y, Ren S Q, et al. Deep residual learning for image recognition[C/OL]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, June 27–30, 2016. (2016–12–12)[2021–03–10]. <https://ieeexplore.ieee.org/document/7780459>.
 - 13 Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search[J]. Nature, 2016, 529(7 587): 484–489.
 - 14 Zhu H, Xiao F, Sun L, et al. R-TTWD: Robust device-free through-the-wall detection of moving human with WiFi[J]. IEEE Journal on Selected Areas in Communications, 2017, 35(5): 1 090–1 103.
 - 15 Xin T, Guo B, Wang Z, et al. FreeSense: indoor human identification with WiFi signals[C/OL]//2016 IEEE Global Communications Conference (GLOBECOM), Washington, DC, USA, Dec 4–8, 2016. (2017–02–06)[2021–03–10]. <https://ieeexplore.ieee.org/document/7841847>.

Indoor Personnel Behavior Monitoring Technology Based on WIFI Information Entropy Feature Analysis

Du Yufeng^{1,2,3}, Wang Chundong^{1,2,3}, Yang Wenjun^{1,2,3}, Zhang Weining^{1,2,3}, Wang Zhuoyue^{1,2,3}

(1. Key Laboratory of Computer Vision and System, Ministry of Education, Tianjin 300384, China;

2. Tianjin Key Laboratory of Intelligence Computing and Novel Software Technology, Tianjin 300384, China;

3. National Engineering Laboratory for Computer Virus Prevention and Control Technology, Tianjin 300384, China)

Abstract: There are some limitations among existing indoor monitoring technologies, such as blind areas and high costs. On the contrary, wireless sensing technology has been widely researched for its non-line of sight and passive. The existing detection methods based on wireless signals mostly adopt the measured values of signal strength and channel state information (CSI). However, the experiment proves that signals received from the same device vary with different antennas. The calculated entropy value of the phase difference of the time-frequency map between different antennas can be used as effective feature to improve the detection accuracy. The phase difference features extracted from the data collected through the wireless devices in three common indoor environments were used to make a comparison with existing feature extraction methods. Meanwhile Support Vector Machine (SVM) and neural network classification methods were selected for comparison. The results show that the accuracy and robustness are higher.

Keywords: wireless sensing; indoor security; channel state information; information entropy